

# MagicalBrush 影视创作平台 — 架构决策与实施方案 v2

日期: 2026-07-15 基于: plan20260708.md (Baizor-API + Hermes-Agent 方案) 焦点: huayu-drama-4 已接入, 评估 HermesAgent 编排 vs 直接 LLM 调用两条路径

## O、当前进展

截至 7 月 15 日, 以下基础设施已落地:

| 已完成项                      | 状态                       | 位置                                                                    |
|---------------------------|--------------------------|-----------------------------------------------------------------------|
| huayu-drama-4 注册为图像生成模型   | <input type="checkbox"/> | common/model.go ImageGenerationModels                                 |
| Image Playground 前端       | <input type="checkbox"/> | web/default/src/features/image-playground/                            |
| Image Playground 路由       | <input type="checkbox"/> | /pg/images/generations + /api/user/image-playground/*                 |
| 默认模型设为 huayu-drama-4      | <input type="checkbox"/> | constants.ts, index.tsx defaultModel                                  |
| 图像生成历史 (服务端持久化)           | <input type="checkbox"/> | controller/image_playground_history.go                                |
| 视频生成 API 路由               | <input type="checkbox"/> | router/video-router.go (/v1/video/generations, /v1/videos)            |
| 7+ 视频供应商适配器               | <input type="checkbox"/> | relay/channel/task/ (klings, sora, vidu, hailuo, doubao, ali, gemini) |
| HermesExecutionTask 长任务模型 | <input type="checkbox"/> | model/hermes_execution_task.go                                        |
| Hermes Playground 前端      | <input type="checkbox"/> | web/default/src/features/hermes-playground/                           |
| BillingSession 全生命周期计费    | <input type="checkbox"/> | service/billing_session.go                                            |

**关键现状:** huayu-drama-4 目前以图像生成模型身份接入, 走 OpenAI Images API 兼容协议。若该模型同时支持视频生成, 需要扩展为双模态 (图像 + 视频), 或注册独立的视频模型名称。

## 一、核心决策: HermesAgent 编排 vs 直接 LLM 调用

### 1.1 两条路径对比

路径 A: HermesAgent 编排 (plan20260708 原方案)

用户输入 → Baizor-API → HermesExecutionTask 入队  
→ Hermes Agent 加载 Skill (script-analyzer 等)  
→ Agent 调 LLM (通过 Baizor-API /v1/chat/completions)  
→ Agent 调工具 (图像生成、视频生成、FFmpeg 等)  
→ Agent 回写结果到 Baizor-API  
→ 前端展示

路径 B: 直接 LLM 调用 (轻量方案)

用户输入 → Baizor-API Go 后端  
→ Go 代码调 /v1/chat/completions (structured output)  
→ 解析 JSON → 批量调 /v1/images/generations + /v1/video/generations  
→ 结果入库 → 前端展示

### 1.2 维度评估

| 维度     | 路径 A: HermesAgent                       | 路径 B: 直接 LLM                         | 推荐 |
|--------|-----------------------------------------|--------------------------------------|----|
| 剧本拆解   | Skill 定义 prompt + 输出格式, Agent 自动重试/修正   | Go 代码硬编码 prompt, 需自行处理重试和格式校验        | A  |
| 多步编排   | Agent 原生支持: 拆解 → 规划 → 生成 → 校验 → 修复, 全自动 | 需 Go 代码编排 pipeline, 每步写状态机           | A  |
| 工具调用   | 109+ 已有工具 + FFmpeg terminal + 图像/视频 API | 只能调 Baizor-API REST 端点, FFmpeg 需额外服务 | A  |
| 角色一致性  | Agent 可跨镜头记忆上下文, 自主决策是否需要修复             | 需 Go 代码显式传递上下文, 逻辑复杂                 | A  |
| 异常处理   | Agent 可解释错误、自动调整参数重试                    | 硬编码错误处理分支                            | A  |
| 实时交互   | Hermes WebSocket 流式输出, 前端已有 Playground  | 需新建 SSE/WS 接口                        | A  |
| 延迟     | Agent 启动 + LLM 多轮 ≈ 20-60s 额外开销         | 单次 LLM 调用 ≈ 3-10s                    | B  |
| 简单任务   | 小题大做: 单张图生成不需要 Agent                    | 直接调 API, 毫秒级                         | B  |
| 可控性    | Agent 行为有随机性, prompt 调优周期长              | Go 代码完全确定性                           | B  |
| 部署复杂度  | 需 Python + Hermes 运行时                   | 纯 Go, 单二进制                           | B  |
| GPU 成本 | Agent 本身需 LLM token, 每次编排 ≈ 数千 token    | 无额外 LLM 开销                           | B  |

1.3 推荐方案：混合架构（A + B 分层）

不必二选一。按任务复杂度分层：

| 用户操作                       |                           |
|----------------------------|---------------------------|
| 简单操作（直接 LLM / 直接 API）      |                           |
| └ 单张图像生成                   | → /v1/images/generations  |
| └ 单段视频生成                   | → /v1/video/generations   |
| └ 图像变体/编辑                  | → /v1/images/edits        |
| └ 风格迁移                     | → Go structured output    |
| 复杂编排（HermesAgent）          |                           |
| └ 剧本拆解+分镜规划                | → script-analyzer Skill   |
| └ 多镜头批量生成                  | → shot-planner + 批量调度     |
| └ 角色一致性校验+修复               | → consistency-guard Skill |
| └ 后期合成                     | → post-production Skill   |
| └ 端到端全流程                   | → workflow-selector Skill |
| 统一基础设施（Baizor-API）         |                           |
| └ 计费（BillingSession）       |                           |
| └ 任务队列（Task + TaskPolling） |                           |
| └ 通道路由（channel_select）     |                           |
| └ 资产管理（StudioAsset）        |                           |

分层原则： - ≤ 1 步操作：Go 后端直接调用 API，零 Agent 开销 - ≥ 2 步 + 需要上下文/决策：委托 HermesAgent - 用户可选：前端提供”快速生成”和”Agent 智能创作”两个入口

二、 huayu-drama-4 模型扩展

2.1 当前状态

huayu-drama-4 已在 ImageGenerationModels 列表中，走 OpenAI Images API 兼容路径。

2.2 需要确认的关键问题

| #  | 问题                                                        | 影响                          |
|----|-----------------------------------------------------------|-----------------------------|
| Q1 | huayu-drama-4 是否同时支持视频生成？还是有独立模型名（如 huayu-drama-4-video）？ | 决定是否需要注册视频模型                |
| Q2 | 视频生成 API 是异步任务模式（提交 → 轮询）还是同步返回？                          | 决定走 Task 适配器还是同步 relay      |
| Q3 | 视频 API 端点格式？兼容 OpenAI Videos API 还是自定义？                   | 决定是否需要新建 Channel Adapter    |
| Q4 | 支持 image-to-video（图生视频）吗？                                 | 影响分镜 pipeline（先生成关键帧图像再转视频） |
| Q5 | 最大视频时长 / 分辨率限制？                                           | 影响分镜规划的镜头时长设计               |

2.3 扩展方案（基于假设：支持视频，异步任务模式）

2.3.1 模型注册

```
// common/model.go - 新增视频生成模型列表
VideoGenerationModels = []string{
    "huayu-drama-4",    // 双模态: 图像 + 视频
    "kling-video",
    "vidu-video",
    "hailuo-video",
    // ... 已有视频模型
}

func IsVideoGenerationModel(modelName string) bool {
    // 类似 IsImageGenerationModel 的实现
}
```

2.3.2 双模态路由

huayu-drama-4 同时出现在图像和视频模型列表中，由请求路径区分： - POST /v1/images/generations + model=huayu-drama-4 → 图像生成 - POST /v1/video/generations + model=huayu-drama-4 → 视频生成

2.3.3 Channel Adapter（如果不兼容现有 OpenAI 格式）

```
relay/channel/task/huayu/
├─ adaptor.go      - 实现 TaskAdaptor 接口
├─ constants.go   - API 常量
├─ dto.go          - 请求/响应 DTO
├─ image.go        - 图像生成（可能已由现有 OpenAI adapter 处理）
└─ video.go        - 视频生成
```

三、修订后的模块清单

相比 plan20260708，以下模块有变化（标 □ 为新增，□ 为修订，□ 为沿用）：

模块 1：Web 工作台 □ 沿用

（同 plan20260708 模块 1，无变化）

模块 2：AI 创作引擎 □ 修订

原方案：全部通过 HermesAgent Skill 编排 修订方案：分层混合

2A. 快速生成层（Go 后端直接调用）

新建 Go service 处理简单创作：

```
// service/studio_quick_gen.go
type QuickGenService struct{}

// 单张图像生成 - 直接调 /v1/images/generations
func (s *QuickGenService) GenerateImage(ctx context.Context, req *dto.StudioImageReq) (resp *dto.StudioImage, err error) {
    // 1. 构造 OpenAI Images API 请求
    // 2. 调用 relay (走 Baizor-API 内部路由, 复用计费/通道选择)
    // 3. 结果入 StudioAsset
    return resp, nil
}

// 单段视频生成 - 直接调 /v1/video/generations
func (s *QuickGenService) GenerateVideo(ctx context.Context, req *dto.StudioVideoReq) (resp *dto.StudioVideo, err error) {
    // 1. 构造视频生成请求
    // 2. 提交 Task → 返回 task_id
    // 3. 轮询完成后入 StudioAsset
    return resp, nil
}

// 剧本快速拆解 - 单次 LLM structured output
func (s *QuickGenService) QuickAnalyzeScript(ctx context.Context, script string) (analysis *dto.ScriptAnalysis, err error) {
    // 1. 构造 system prompt (内嵌 script-analyzer 格式要求)
    // 2. 调 /v1/chat/completions, response_format: json_schema
    // 3. 解析 JSON 返回
    return analysis, nil
}
```

## 2B. 智能编排层 (HermesAgent)

保留 plan20260708 的 Skill 设计, 但只用于复杂场景:

```
hermes-agent/skills/magicalbrush/
├── script-analyzer.md      剧本 → 结构化场景/镜头/角色列表 (深度拆解)
├── shot-planner.md        场景 → 镜头规划 + 自动选择景别/运镜
├── character-designer.md   角色 → 参考图 prompt + 一致性参数
├── batch-generator.md     批量镜头生成编排 (调度 + 重试 + 进度)
├── consistency-guard.md   多镜头角色一致性校验 + 修复
├── quality-checker.md     质量评分 + 异常诊断 + 修复建议
├── post-production.md     素材 → FFmpeg 后期编排
└── full-pipeline.md       端到端全流程 (入口 Skill, 编排其他 Skill)
```

去掉的 Skill: - workflow-selector.md → 合并到 full-pipeline.md - copyright-register.md → 降级为 Phase 3, 不在 Skill 中实现

## 2C. 集成入口 API

```
// controller/studio_create.go

// 快速生成 - 直接返回结果, 无 Agent 开销
// POST /api/studio/project/{id}/quick-generate
func StudioQuickGenerate(c *gin.Context) {
    // req.type = "image" | "video" | "script_analyze"
    // 调 QuickGenService
}

// 智能创作 - 异步 Agent 任务
// POST /api/studio/project/{id}/agent-create
func StudioAgentCreate(c *gin.Context) {
    // req.skill = "script-analyzer" | "batch-generator" | "full-pipeline"
    // 创建 HermesExecutionTask
    // 返回 task_id, 前端通过 WS 跟踪进度
}
```

## 模块 3: Skill Registry 沿用

(同 plan20260708 模块 3)

## 模块 4: 队列与调度 沿用

(同 plan20260708 模块 4, 但 ChannelTypeSeedance 改为 ChannelTypeHuayu 或保留通用名)

模块 5：huayu-drama-4 适配器 □ 修订

原方案：新建 SeeDance 适配器 修订方案：视 huayu-drama-4 的 API 协议而定

| 情况                          | 方案                                     |
|-----------------------------|----------------------------------------|
| API 兼容 OpenAI Images/Videos | 无需新建适配器，现有 OpenAI adapter 直接路由         |
| API 兼容 OpenAI 但有扩展字段        | 在 OpenAI adapter 中加 huayu-drama-4 特殊处理 |
| API 完全自定义                   | 新建 relay/channel/task/huayu/ 适配器       |

当前优先确认 Q1-Q5 问题后再决策。

模块 6：资产库 □ 沿用

（同 plan20260708 模块 6）

模块 7：后期服务 □ 沿用

（同 plan20260708 模块 7）

模块 8：审计/确权 □ 沿用

（同 plan20260708 模块 8，降级为 Phase 3）

四、修订后的实施路线

Phase 0（当前 ~ W2）：验证 huayu-drama-4 能力边界 □

目标：明确 huayu-drama-4 图像+视频能力，跑通基础 API 调用

| 周  | 任务                                       | 产出                                         |
|----|------------------------------------------|--------------------------------------------|
| W1 | 确认 huayu-drama-4 视频 API 规范（Q1-Q5）        | API 文档整理 / 测试脚本                            |
| W1 | Image Playground 验证 huayu-drama-4 图像生成效果 | 质量评估报告                                     |
| W2 | 如需视频适配器，实现 MVP adapter                   | relay/channel/task/huayu/ 或确认现有 adapter 可用 |
| W2 | 验证 huayu-drama-4 视频生成流程（提交 → 轮询 → 取结果）   | 端到端调用验证                                    |

Phase 0 验收标准： - 通过 API 成功生成图像和视频 - 确认 API 协议兼容性，决定适配器方案 - 确认视频时长/分辨率限制

Phase 1（W3 ~ W10）：最小闭环 — 快速创作 + Agent 辅助

目标：用户通过 Web 工作台完成 剧本→分镜→图像/视频 全流程

| 周     | 任务              | 产出                                                      |
|-------|-----------------|---------------------------------------------------------|
| W3-4  | 后端领域模型          | StudioProject, StudioCharacter, StudioScene, StudioShot |
| W3-4  | Studio API 端点   | /api/studio/ CRUD + 快速生成 + Agent 创作                     |
| W5-6  | 快速生成 Service    | studio_quick_gen.go (图像、视频、剧本拆解)                        |
| W5-7  | Hermes Skill 编写 | script-analyzer.md, shot-planner.md, batch-generator.md |
| W7-8  | 前端 Studio 页面    | 项目创建 + 角色管理 + 分镜列表 (网格视图)                               |
| W8-9  | 快速生成 UI         | 单镜头图像/视频生成面板 (复用 Image Playground 组件)                   |
| W9-10 | Agent 创作 UI     | 连接 Hermes WS, 展示 Agent 执行进度和结果                          |

**Phase 1 验收标准：** - ☐ 用户提交剧本文本，选择”快速拆解”→ 3-10s 返回结构化场景/镜头列表 - ☐ 用户选择”Agent 智能拆解”→ Agent 深度分析 → 更详细的镜头规划 - ☐ 每个镜头可一键”快速生成”图像或视频 - ☐ 可一键”批量生成”→ Agent 编排所有镜头的图像/视频 - ☐ 所有生成走 BillingSession 正确计费 - ☐ 结果展示在分镜板页面

**Phase 2（W11 ~ W16）：资产库 + 角色一致性 + 分镜编辑器**

(同 plan20260708 Phase 2，略调时间线)

| 周      | 任务        | 产出                                                 |
|--------|-----------|----------------------------------------------------|
| W11-12 | 资产库后端     | StudioAsset + 对象存储 (MinIO/本地)                      |
| W12-14 | 角色一致性     | character-designer.md + consistency-guard.md Skill |
| W13-15 | 分镜编辑器 MVP | Konva.js Canvas (拖拽排序、属性面板)                        |
| W15-16 | 联调 + 质量   | quality-checker.md Skill + 端到端测试                   |

**Phase 3（W17 ~ W22）：后期 + 审计 + 私有化**

(同 plan20260708 Phase 3)

五、技术决策更新

| 决策点      | plan20260708 方案 | plan20260715 修订        | 理由                                     |
|----------|-----------------|------------------------|----------------------------------------|
| AI 编排架构  | 全 HermesAgent   | 混合：简单→Go 直调，复杂→Agent   | 避免简单操作的 Agent 启动开销                     |
| 默认图像模型   | SeeDance 2.0    | huayu-drama-4（已接入）     | 已配置完成，可直接使用<br>需先验证 huayu-drama-4 视频能力 |
| 视频生成     | SeeDance 新建适配器  | 待确认 API 后决定            | 减少前端新建工作量                              |
| 前端快速生成   | 无（全走 Agent）     | 复用 Image Playground 组件 | Hermes Playground 已实现 WS               |
| Agent 通信 | REST + 轮询       | WebSocket（已有）          | 仍然是最佳选择                                |
| 分镜编辑器    | Konva.js        | Konva.js（不变）           | 不变                                     |
| 对象存储     | MinIO           | MinIO（不变）              |                                        |

六、风险更新

| 风险                     | 等级   | 变化                       | 应对                           |
|------------------------|------|--------------------------|------------------------------|
| SeeDance 2.0 API 规范不明确 | ⚠    | 降低 → huayu-drama-4 图像已跑通 | Phase 0 集中验证视频能力             |
| huayu-drama-4 视频能力限制   | □ 新增 | —                        | 若不支持视频，用 Kling/Hailuo 补充     |
| Agent 延迟影响用户体验         | □ 新增 | —                        | 混合架构：简单操作走快速通道               |
| 角色一致性效果                | □    | 不变                       | 同 plan20260708               |
| 分镜 Canvas 开发量          | □    | 不变                       | Phase 1 用列表视图，Phase 2 Canvas |

七、下一步行动 (Action Items)

本周（7/15 ~ 7/21）

- ☐ P0: 确认 huayu-drama-4 视频生成 API 规范（联系模型提供方或查阅文档）
- ☐ P0: 用现有 Image Playground 系统性测试 huayu-drama-4 图像生成效果
- ☐ P1: 起草 StudioProject / StudioShot Go 模型文件（先不建表，确认字段）
- ☐ P1: 起草 script-analyzer.md Skill 初稿（验证 LLM 剧本拆解效果）
- ☐ P2: 评估是否将 huayu-drama-4 同时注册到 VideoGenerationModels

下周（7/22 ~ 7/28）

- ☐ 根据 API 确认结果，决定视频适配器方案
- ☐ 开始 Phase 1 后端领域模型开发
- ☐ 开始 Hermes Skill 编写和测试