

MagicalBrush 影视创作平台 — 架构决策与实施方案 v2

MagicalBrush 影视创作平台 — 架构决策与实施方案 v2

日期：2026-07-15 基于：plan20260708.md (Baizor-API + Hermes-Agent 方案) 焦点：huayu-drama-4 全模态能力确认，混合架构设计，配置建议

〇、当前进展与服务器实况

0.1 Baizor-API 侧已完成

已完成项	状态	位置
huayu-drama-4 注册为图像生成模型	☑	common/model.go ImageGenerationModels
Image Playground 前端	☑	web/default/src/features/image-playground/ /pg/images/generations + /api/user/image-playground/*
Image Playground 路由	☑	constants.ts, index.tsx defaultModel
默认模型设为 huayu-drama-4	☑	controller/image_playground_history.go
图像生成历史（服务端持久化）	☑	router/video-router.go (/v1/video/generations, /v1/videos)
视频生成 API 路由	☑	relay/channel/task/ (kling, sora, vidu, hailuo, doubao, ali, gemini)
7+ 视频供应商适配器	☑	model/hermes_execution_task.go
HermesExecutionTask 长任务模型	☑	web/default/src/features/hermes-playground/
Hermes Playground 前端	☑	service/billing_session.go
BillingSession 全生命周期计费	☑	

0.2 anne-1 服务器实况（8× RTX 4090 24GB = 192GB）

通过 ssh anne-1 查看 /lucky/huazhen/docker-compose.yml，确认如下部署：

llama-proxy-huazhen (:8080)
统一入口 - 按路径路由到不同后端
/v1/chat/completions → llama-huazhen (文本)
或 llama-v1-huazhen (含图片时自动切换)
/v1/images/generations → ideogram4-huazhen
/v1/videos/generations → sulphur2-huazhen → comfyui-huazhen
/v1/models → 静态列表

服务清单

容器	功能	GPU	模型/引擎	对外别名
llama-huazhen	文本 Chat	GPU 0,1,2,3 (4卡)	Qwable-v1 (IQ4_XS, 262K ctx)	qwable-v1, huazhen-v1, huazhen-fable-5
llama-v1-huazhen	视觉理解	GPU 6 (1卡)	Qwen3-VL-30B-A3B (IQ4_XS)	qwen3-v1-30b-a3b, huazhen-v1
ideogram4-huazhen	图像生成	GPU 7 (1卡)	Ideogram 4 (nf4量化)	ideogram-4
comfyui-huazhen	ComfyUI 后端	GPU 4,5 (2卡)	LTX 2.3 / Sulphur 2	— (内部)
sulphur2-huazhen	视频生成 API	— (CPU, 调 ComfyUI)	Sulphur 2 (fp8)	sulphur-2
llama-proxy-huazhen	统一代理	— (CPU)	—	对外 :8080

GPU 分配现状

GPU 0-3 (4× 24GB = 96GB) → llama-huazhen (文本LLM, 4卡tensor split)
GPU 4-5 (2× 24GB = 48GB) → comfyui-huazhen (视频生成后端)
GPU 6 (1× 24GB = 24GB) → llama-v1-huazhen (视觉理解)
GPU 7 (1× 24GB = 24GB) → ideogram4-huazhen (图像生成)

视频生成当前参数

参数	当前值	说明
最大分辨率	1280px (长边)	SULPHUR2_MAX_SIDE=1280
默认尺寸	512×768	DEFAULT_SIZE
帧数	97帧	SULPHUR2_NUM_FRAMES=97
帧率	24fps	→ 约 4 秒视频
推理步数	50步	NUM_INFERENCE_STEPS=50
Guidance Scale	3.6	
最大并发	1 (同步阻塞)	sulphur2 单请求阻塞等待 ComfyUI
超时	3600s (1小时)	PROXY_UPSTREAM_TIMEOUT

一、Q1-Q5 确认结果

#	问题	确认答案
Q1	huayu-drama-4 支持哪些能力？	☒ 全模态 ：chat + image + image-vl + video，由 llama-proxy-huazhen 统一代理，按路径路由到 4 个后端
Q2	视频生成是异步还是同步？	☒ 异步 。sulphur2 本身是同步阻塞（等 ComfyUI 完成），但 Baizor-API 侧应通过 Task 系统异步封装
Q3	视频 API 格式？	☒ 已兼容 OpenAI Videos API ：POST /v1/videos/generations，请求 {prompt, size, n, ...}，响应 {created, data: [{b64_json}]}
Q4	支持 image-to-video？	☒ 当前不支持，可在服务器扩展 。sulphur2 当前仅 text-to-video，i2v 需要扩展 ComfyUI 工作流
Q5	最大配置建议？	☒ 见下方”最高配建议”

二、核心决策：混合架构（A + B 分层）

结论：不必二选一

经评估，推荐 **HermesAgent + 直接 LLM/API 调用分层混合**：

维度	路径 A: HermesAgent	路径 B: 直接 LLM	推荐
剧本拆解	Skill 定义 prompt + 输出格式，Agent 自动重试/修正	Go 代码硬编码 prompt，需自行处理重试和格式校验	A
多步编排	Agent 原生支持：拆解 → 规划 → 生成 → 校验 → 修复，全自动	需 Go 代码编排 pipeline，每步写状态机	A
工具调用	109+ 已有工具 + FFmpeg terminal + 图像/视频 API	只能调 Baizor-API REST 端点，FFmpeg 需额外服务	A
角色一致性	Agent 可跨镜头记忆上下文，自主决策是否需要修复	需 Go 代码显式传递上下文，逻辑复杂	A
异常处理	Agent 可解释错误、自动调整参数重试	硬编码错误处理分支	A
实时交互	Hermes WebSocket 流式输出，前端已有 Playground	需新建 SSE/WS 接口	A
延迟	Agent 启动 + LLM 多轮 ≈ 20-60s 额外开销	单次 LLM 调用 ≈ 3-10s	B
简单任务	小题大做：单张图生成不需要 Agent	直接调 API，毫秒级	B
可控性	Agent 行为有随机性，prompt 调优周期长	Go 代码完全确定性	B
部署复杂度	需 Python + Hermes 运行时	纯 Go，单二进制	B

分层架构

用户操作
简单操作（Go 后端直接调用，≤1步）
└ 单张图像生成 → /v1/images/generations
└ 单段视频生成 → /v1/videos/generations (Task异步)
└ 图像理解/描述 → /v1/chat/completions (VL模型)
└ 剧本快速拆解 → /v1/chat/completions (structured)
复杂编排（HermesAgent，≥2步 + 需决策）
└ 剧本深度拆解+分镜规划 → script-analyzer Skill
└ 多镜头批量生成 → batch-generator Skill
└ 角色一致性校验+修复 → consistency-guard Skill
└ 后期合成（FFmpeg） → post-production Skill
└ 端到端全流程 → full-pipeline Skill
统一基础设施（Baizor-API）
└ 计费（BillingSession）
└ 任务队列（Task + TaskPolling）
└ 通道路由（channel_select → llama-proxy-huazhen）
└ 资产管理（StudioAsset）

三、Baizor-API 配置建议

3.1 模型注册 (common/model.go)

现状： huayu-drama-4 仅在 ImageGenerationModels 中。

建议： huayu-drama-4 是全模态的统一品牌名。但底层实际是 4 个不同模型，建议在 Baizor-API 注册多个模型别名，映射到同一个 Channel (llama-proxy-huazhen)，由 proxy 按路径自动路由。

```
// common/model.go - 修改建议

var (
    ImageGenerationModels = []string{
        "dall-e-3",
        "dall-e-2",
        "gpt-image-1",
        "gpt-image-2",
        "huayu-drama-4",           // ← 保留，图像生成
        "prefix:imagen-",
        "flux-",
        "flux.1-",
    }

    // 新增：视频生成模型列表
    VideoGenerationModels = []string{
        "huayu-drama-4",           // 同名，由请求路径区分
        "huayu-drama-4-video",     // 或显式的视频模型别名
    }
)

// 新增
func IsVideoGenerationModel(modelName string) bool {
    modelName = strings.ToLower(modelName)
    for _, m := range VideoGenerationModels {
        if strings.Contains(modelName, m) {
            return true
        }
    }
    return false
}
```

3.2 Channel 配置 (管理后台)

在 Baizor-API 管理后台添加 Channel：

通道名称：huazhen-cluster
类型：OpenAI (兼容)
Base URL: http://<anne-1-ip>:8080 ← llama-proxy-huazhen 对外端口
API Key: <LLAMA_API_KEY>
模型列表：huayu-drama-4, huazhen-v1, huazhen-v1, huazhen-fable-5
优先级：10
权重：100
分组：default

关键： 由于 llama-proxy-huazhen 内部按路径路由，一个 Channel 即可覆盖 chat + image + video 所有请求。Baizor-API 只需按 model name 将请求路由到这个 Channel。

3.3 llama-proxy-huazhen 配置建议

3.3.1 增加 huayu-drama-4 到 PROXY_MODELS

当前：

- PROXY_MODELS=huazhen-v1,huazhen-v1,ideogram-4,sulphur-2

建议：

- PROXY_MODELS=huayu-drama-4,huazhen-v1,huazhen-v1,ideogram-4,sulphur-2

并在 proxy.py 中将 huayu-drama-4 作为统一别名，所有 4 个能力的请求都接受 model: huayu-drama-4: - /v1/chat/completions + model=huayu-drama-4 → 路由到 llama-huazhen - /v1/chat/completions + model=huayu-drama-4 + 含图片 → 路由到 llama-vl-huazhen - /v1/images/generations + model=huayu-drama-4 → 路由到 ideogram4-huazhen - /v1/videos/generations + model=huayu-drama-4 → 路由到 sulphur2-huazhen

3.3.2 新增异步视频 API 支持

当前问题： sulphur2 是同步阻塞（一个视频生成可能要 5-30 分钟），proxy 直接透传等待。对于 Baizor-API 的 Task 异步系统，建议两种方案：

方案 A（推荐）：proxy 层新增异步封装

在 llama-proxy-huazhen 中新增 OpenAI Videos API 异步模式支持：

```
# proxy.py 新增路由
ALLOWED_PATHS.add("/v1/videos")          # POST 提交 + GET 查询
ALLOWED_PATHS.add("/v1/videos/{id}")      # GET 查询单个

# POST /v1/videos → 提交任务, 立即返回 task_id
# GET /v1/videos/{id} → 查询任务状态/结果
```

请求格式（兼容 OpenAI Videos API）：

```
POST /v1/videos
{
  "model": "huayu-drama-4",
  "input": [{"type": "text", "text": "A cinematic shot of..."}],
  "size": "1280x720",
  "duration": 5
}
```

```
→ 202 Accepted
{
  "id": "video_abc123",
  "status": "generating",
  "created_at": 1752600000
}
```

```
GET /v1/videos/video_abc123

→ 200 OK (完成时)
{
  "id": "video_abc123",
  "status": "completed",
  "video": {"url": "https://..."},
  "created_at": 1752600000
}
```

方案 B：Baizor-API 侧 Task 封装

不改 proxy，在 Baizor-API 的 Task 系统中异步封装：- POST /v1/video/generations → 创建 Task → 后台调 proxy 的同步 /v1/videos/generations → 完成后更新 Task - 复用现有 relay/channel/task/ 适配器模式

推荐方案 A，因为：1. 与 Baizor-API 现有视频路由 (/v1/videos) 完全兼容 2. proxy 端可管理队列和并发，避免 ComfyUI 被压垮 3. Baizor-API 无需新建适配器

四、最高配建议（Q5）

4.1 视频生成参数 — 最高配

```
# docker-compose.yml - sulphur2-huazhen 环境变量修改
- SULPHUR2_MAX_SIDE=1920      # 当前 1280 → 提升到 1080p
- SULPHUR2_NUM_FRAMES=193     # 当前 97 → 约 8 秒 @24fps
- SULPHUR2_FPS=24             # 保持 24fps（电影标准）
- SULPHUR2_NUM_INFERENCE_STEPS=75 # 当前 50 → 更高质量
- SULPHUR2_GUIDANCE_SCALE=3.6  # 保持不变
```

参数	当前	最高配	影响
MAX_SIDE	1280	1920	支持 1080p (1920×1080)，需更多显存
NUM_FRAMES	97 (~4s)	193 (~8s)	单镜头 8 秒，影视场景够用
FPS	24	24	电影标准帧率
NUM_INFERENCE_STEPS	50	75	更细腻，生成时间 ×1.5
预计单视频耗时	~5-15 min	~15-40 min	GPU 4,5 两卡

注意：1920px + 193 帧可能在 2× RTX 4090 (48GB) 上 OOM。建议：- 先试 1280 + 193 帧（扩时长不扩分辨率）- 再试 1920 + 97 帧（扩分辨率不扩时长）- 最后试 1920 + 193 帧，如 OOM 则降回

4.2 图像生成参数 — 最高配

```
# docker-compose.yml - ideogram4-huazhen 环境变量
- IDEOGRAM4_MAX_SIDE=2048      # 当前已是 2048，保持
- IDEOGRAM4_QUANTIZATION=nf4    # 当前 nf4（单卡 24G 极限）
- IDEOGRAM4_MAGIC_PROMPT=on     # 保持开启 magic prompt
- IDEOGRAM4_FILTER_CHECK=on     # 保持安全水印检测
```

图像已是最高配（2048px, nf4量化在单卡24G极限）。如需更高质量：- 升级到 bf16 量化需 2 卡（48GB），但需改 ideogram4 服务支持多卡

4.3 Image-to-Video (i2v) 扩展方案

目标：支持先生成关键帧图像 → 再转视频，实现影视分镜 pipeline。

方案：扩展 ComfyUI 工作流 + sulphur2 API

Step 1: 新增 i2v ComfyUI 工作流

```
comfyui-workflows/
├─ ltx23_t2v_base_api.json    ← 现有 text-to-video
└─ ltx23_i2v_base_api.json   ☑ ← 新增 image-to-video
```

LTX-Video 2.3 原生支持 image-to-video（LTXVImgToVideoInplace 节点），当前工作流中已有该节点（NODE_BYPASS_I2V_22），只是被 bypass 了。

Step 2: 修改 sulphur2/server.py

```
# sulphur2/server.py - 新增 i2v 端点

# 新增路由
ALLOWED_PATHS.add("/v1/videos/image-to-video")

# POST /v1/videos/image-to-video
# {
#     "model": "huayu-drama-4",
#     "image": "data:image/png;base64,...", // 或 URL
#     "prompt": "the character walks forward...",
#     "size": "1280x720",
#     "num_frames": 97
# }
```

核心改动： 1. 取消 NODE_BYPASS_I2V_22 的 bypass（设为 false） 2. 将输入图片传入 ComfyUI 的 LoadImage 节点 3. 其余参数复用现有 t2v 逻辑

Step 3: proxy路由更新

```
# docker-compose.yml - Llama-proxy-huazhen
- UPSTREAM_VIDEO_URL=http://sulphur2-huazhen:8080
# proxy.py 新增 ALLOWED_PATHS
# "/v1/videos/image-to-video"
```

预计工作量：2-3 天（ComfyUI 工作流已有 i2v 节点，只需开启 + API 封装）

4.4 后续扩展：更多 GPU 时的方案

如果未来有更多 GPU 可用，优先考虑：

优先级	扩展方向	所需资源	效果
P0	视频生成并发	+2 卡 → ComfyUI 第二实例	视频生成并发 ×2
P1	视频分辨率	+2 卡 → ComfyUI 4卡	稳定 1920p + 长时长
P2	图像生成高精度	+1 卡 → ideogram4 双卡 bf16	图像质量提升
P3	LoRA 训练	+2 卡 → 独立训练实例	支持角色 LoRA 训练
P4	文本 LLM 扩容	+2 卡 → 6 卡 tensor split	更大 ctx 或更快推理

五、修订后的模块清单

相比 plan20260708，以下模块有变化（标  为新增， 为修订， 为沿用）：

模块 1: Web 工作台 沿用

（同 plan20260708 模块 1，无变化）

模块 2: AI 创作引擎 混合架构

2A. 快速生成层（Go 后端直接调用）

```
// service/studio_quick_gen.go
type QuickGenService struct{}

// 单张图像 - 直接调 relay /v1/images/generations
func (s *QuickGenService) GenerateImage(ctx, req) (*resp, error)

// 单段视频 - 提交 Task, 异步调 /v1/videos/generations
func (s *QuickGenService) GenerateVideo(ctx, req) (*resp, error)

// 图生视频 - 提交 Task, 异步调 /v1/videos/image-to-video
func (s *QuickGenService) ImageToVideo(ctx, req) (*resp, error)

// 图像理解 - 调 /v1/chat/completions + 图片 (路由到 VL 模型)
func (s *QuickGenService) DescribeImage(ctx, req) (*resp, error)

// 剧本快速拆解 - 单次 structured output
func (s *QuickGenService) QuickAnalyzeScript(ctx, script) (*analysis, error)
```

2B. 智能编排层 (HermesAgent)

```
hermes-agent/skills/magicalbrush/
├─ script-analyzer.md      剧本 → 结构化场景/镜头/角色列表
├─ shot-planner.md        场景 → 镜头规划 + 景别/运镜选择
├─ character-designer.md   角色 → 参考图 prompt + 一致性参数
├─ batch-generator.md     批量镜头生成编排 (图→视频 pipeline)
├─ consistency-guard.md   多镜头角色一致性校验 + 修复
├─ quality-checker.md     质量评分 + 异常诊断 + 修复建议
├─ post-production.md     素材 → FFmpeg 后期编排
└─ full-pipeline.md       端到端: 拆解→规划→生图→生视频→合成
```

2C. 集成入口 API

```
// 快速生成 - 直接返回/异步Task
POST /api/studio/project/{id}/quick-generate
  body: { type: "image"|"video"|"i2v"|"describe"|"analyze", ... }

// Agent 智能创作 - HermesExecutionTask
POST /api/studio/project/{id}/agent-create
  body: { skill: "script-analyzer"|"batch-generator"|"full-pipeline", ... }
```

模块 3: Skill Registry 沿用

模块 4: 队列与调度 沿用

模块 5: huayu-drama-4 适配器 大幅简化

结论: 不需要新建 Channel Adapter。

原因: 1. 图像生成走 OpenAI Images API → 现有 OpenAI adapter 直接可用 2. 视频生成走 OpenAI Videos API → 走 Task 系统 + 现有 Sora/Kling 适配器模式 3. Chat 走 OpenAI Chat API → 现有 OpenAI adapter 4. 所有请求由 llama-proxy-huazhen 内部路由, 对 Baizor-API 完全透明

唯一需要做的: 1. common/model.go 新增 VideoGenerationModels 列表 2. 管理后台添加 huazhen-cluster Channel 3. 确保 Baizor-API 的视频 Task 适配器兼容 sulphur2 的响应格式

模块 6-8 沿用

(同 plan20260708)

六、修订后的实施路线

Phase 0 已完成 ☒

Q1-Q5 已确认，无需额外验证周期。

Phase 1（本周起 ~ W8）：最小闭环

目标：用户通过 Web 工作台完成 剧本→分镜→图像/视频 全流程

周	任务	产出
W1	common/model.go 注册视频模型 + 管理后台配置 Channel	视频生成路由打通
W1-2	sulphur2 异步 API 封装（proxy 或 Baizor-API Task）	视频异步提交+轮询
W2-3	后端领域模型	StudioProject, StudioCharacter, StudioScene, StudioShot
W3-4	Studio API 端点	/api/studio/ CRUD + 快速生成 + Agent 创作
W3-5	快速生成 Service	studio_quick_gen.go（图像、视频、剧本拆解）
W4-6	Hermes Skill 编写	script-analyzer.md, shot-planner.md, batch-generator.md
W5-7	前端 Studio 页面	项目创建 + 角色管理 + 分镜列表（网格视图）
W6-7	快速生成 UI（复用 Image Playground 组件）	单镜头图像/视频生成面板
W7-8	Agent 创作 UI（复用 Hermes Playground WS）	Agent 进度和结果展示

Phase 1 验收标准： - ☒ 用户提交剧本，“快速拆解” → 3-10s 返回结构化镜头列表 - ☒ 用户选择” Agent 智能拆解” → 深度分析 → 详细镜头规划 - ☒ 每个镜头可一键生成图像（huayu-drama-4, ~30s） - ☒ 每个镜头可一键生成视频（huayu-drama-4, ~5-30min，异步Task） - ☒ 所有生成走 BillingSession 正确计费 - ☒ 分镜板页面展示图像+视频

Phase 2（W9 ~ W14）：i2v + 资产库 + 角色一致性 + 分镜编辑器

周	任务	产出
W9-10	sulphur2 i2v 扩展	ComfyUI i2v 工作流 + API 封装
W9-11	资产库后端	StudioAsset + 对象存储
W11-13	角色一致性 Skill	character-designer.md + consistency-guard.md
W12-14	分镜编辑器 MVP	Konva.js Canvas

Phase 3（W15 ~ W20）：后期 + 审计 + 私有化

（同 plan20260708 Phase 3）

七、配置变更清单（可直接执行）

7.1 Baizor-API 代码变更

文件	变更	优先级
common/model.go	新增 VideoGenerationModels + IsVideoGenerationModel()	P0
common/model.go	确认 huayu-drama-4 同时在图像和视 频列表中	P0

7.2 anne-1 服务器配置变更

文件	变更	优先级
docker-compose.yml	PROXY_MODELS 增加 huayu-drama-4	P0
proxy/proxy.py	模型名 huayu-drama-4 路由支持（所有路径）	P0
docker-compose.yml	SULPHUR2_NUM_FRAMES=193 (8秒视频)	P1
docker-compose.yml	SULPHUR2_NUM_INFERENCE_STEPS=75	P1
sulphur2/server.py	新增 /v1/videos/image-to-video 端点	P2
comfyui-workflows/	新增 ltx23_i2v_base_api.json	P2
proxy/proxy.py	新增异步任务模式（提交→轮询→取结果）	P1

7.3 管理后台配置

新增 Channel:

名称: huazhen-cluster

类型: OpenAI

Base URL: http://<anne-1-ip>:8080

Key: <LLAMA_API_KEY>

模型: huayu-drama-4

优先级: 10

权重: 100

八、风险更新

风险	等级	应对
API 规范不明确	☒ → ☒ 已确认	Q1-Q5 已全部确认
1920p + 193帧 OOM	☒	分步测试：先扩时长再扩分辨率
视频生成耗时长 (15-40min)	☒	Task 异步 + 进度展示 + 允许用户取消
视频并发低（当前 1）	☒	Phase 2 增加 ComfyUI 第二实例
i2v 质量不确定	☒	Phase 2 开始前先人工测试 ComfyUI i2v 效果
角色一致性效果	☒	多方案并行：LoRA + IP-Adapter + 后处理修复
分镜 Canvas 开发量	☒	Phase 1 用列表视图，Phase 2 Canvas

九、下一步行动 (Action Items)

立即执行（本周）

- ☐ **P0:** common/model.go 新增 VideoGenerationModels，注册 huayu-drama-4
- ☐ **P0:** anne-1 docker-compose.yml 的 PROXY_MODELS 增加 huayu-drama-4
- ☐ **P0:** 管理后台添加 huazhen-cluster Channel
- ☐ **P0:** 验证 Baizor-API → proxy → sulphur2 视频生成端到端链路

☐ **P1:** anne-1 试调 SULPHUR2_NUM_FRAMES=193，测试 8s 视频是否 OOM

下周

- ☐ sulphur2 异步 API 封装（选定方案 A 或 B 后实施）
- ☐ 开始 StudioProject / StudioShot 领域模型
- ☐ 起草 script-analyzer.md Skill 初稿